

# 哈尔滨工业大学计算机科学与技术学院

## 实验报告

课程名称: 机器学习

课程类型: 选修

实验题目: 逻辑回归

学号: 1190202110

姓名: 田雪洋

2021 年 10 月 19 日

# 一、实验目的

理解逻辑回归模型，掌握逻辑回归模型的参数估计算法。

## 二、实验要求及实验环境

### 1. 实验要求

实现两种损失函数的参数估计（1，无惩罚项；2. 加入对参数的惩罚），可以采用梯度下降、共轭梯度或者牛顿法等。

验证：1. 可以手工生成两个分别类别数据（可以用高斯分布），验证你的算法。考察类条件分布不满足朴素贝叶斯假设，会得到什么样的结果。

2. 逻辑回归有广泛的用处，例如广告预测。可以到 UCI 网站上，找一实际数据加以测试。

### 2. 实验环境

Windows10; python3.8.6;Pycharm

## 三、设计思想（本程序中的用到的主要算法及数据结构）

对于给定的数据集  $T = \{(x_i, y_i)\}$ ，其中  $x_i \in R^n, y_i \in \{0, 1\}$ ，可以使用 logistics 回归模型来进行分类。为此，我们对数据集进行如下规定：

$$X = \begin{pmatrix} x_1 & x_2 & \cdots & x_n \end{pmatrix}, y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, w^T = \begin{pmatrix} w_1 & w_2 & \cdots & w_n \end{pmatrix}$$

根据 logistics 回归模型，

$$P(y = 1|x) = \frac{e^{wx}}{1 + e^{wx}} = \pi(x), P(y = 0|x) = \frac{1}{1 + e^{wx}} = 1 - \pi(x) \quad (1)$$

则其似然函数为:

$$\prod_{i=1}^n [\pi(x_i)]^{y_i} [1 - \pi(x_i)]^{1-y_i} \quad (2)$$

则其对数似然函数为:

$$L(W) = \sum_{i=1}^n [y_i (w \cdot x_i) - \log(1 + e^{w \cdot x_i})] \quad (3)$$

仿照实验 1 的结论, 为了避免过拟合现象, 我们在似然函数后添加正则项, 得到:

$$L(W) = \sum_{i=1}^n [y_i (w \cdot x_i) - \log(1 + e^{w \cdot x_i})] + \frac{\lambda}{2} \|w\|^2 \quad (4)$$

对  $L(W)$  求极大值, 便可以得到  $w$  的估计值了。在这里我们采用多种方法求解。

## 1. 梯度下降法

首先我们使用梯度下降法来求解, 为此, 我们需要转换为求  $-L(W)$  的极小值。在综合考虑数据集的样本数量后, 我们最终确定目标函数为:

$$\arg \min_w -\frac{1}{n} L(W) \quad (5)$$

则梯度下降法的迭代公式为:

$$W = W - \eta \lambda W - \frac{\eta}{n} \frac{\partial L(W)}{\partial W} = W - \eta \lambda W + \frac{\eta}{n} \sum_{i=1}^n \left( y_i x_i - \frac{x_i}{1 + e^{w \cdot x_i}} \right) \quad (6)$$

其中  $\eta \lambda W$  为正则项。

## 2. 共轭梯度法

此外, 还可以使用共轭梯度法进行求解, 由于共轭梯度法要求系数矩阵为对称矩阵且正定, 但显然本题的一阶导方程不满足, 因此, 对于一般形式的线性方程, 共轭梯度法要求其 **Hessian** 矩阵。其迭代过程如下:

(1) 初始条件

$$g_1 = Hx_1 - b$$

$$d_1 = r_1 = -g_1$$

(2) 迭代式

$$a_k = \frac{d_k^T r_k}{d_k^T H d_k}$$

$$x_{k+1} = x_k + a_k d_k$$

$$r_{k+1} = r_k - a_k H d_k$$

$$\beta_k = \frac{r_{k+1}^T H d_k}{d_k^T H d_k}$$

$$d_{k+1} = r_{k+1} - \beta_k d_k$$

所以只需要求解出似然函数的一阶导数的 Hessian 矩阵即可, Hessian 矩阵  $H = X^T A X$ , 其中,

$$A = \begin{pmatrix} \pi(x_1)[1 - \pi(x_1)] & 0 & \cdots & 0 \\ 0 & \pi(x_2)[1 - \pi(x_2)] & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \pi(x_n)[1 - \pi(x_n)] \end{pmatrix}$$

### 3. 牛顿法

牛顿法的基本思想是用梯度信息和二阶导数对目标函数进行逼近, 然后把极小值作为新的迭代点, 并不断重复这一过程, 直到求出极小点。其步骤可以总结为以下四步:

- (1) 设置初始点及终止条件
- (2) 检验是否满足终止条件
- (3) 计算二阶导数, 并确定搜索方向

$$d_k : \nabla^2 f(x_k) d = -\nabla f(x_k)$$

- (4) 计算下一个迭代点

$$x_{k+1} = x_k + d_k$$

重复步骤 (2)

本题的一阶导数在上文中已经给出, 所以下面只需要求解二阶导数即可:

$$\frac{\partial^2 L}{\partial \mathbf{w} \partial \mathbf{w}^T} = \sum_{i=1}^n \left( x_i x_i^T \frac{e^{w \cdot x_i}}{1 + e^{w \cdot x_i}} \frac{1}{1 + e^{w \cdot x_i}} \right)$$

则牛顿法的完整迭代式为:

$$x_{k+1} = x_k - \alpha \left( \frac{\partial^2 L}{\partial \mathbf{w} \partial \mathbf{w}^T}^{-1} \frac{\partial L(W)}{\partial W} + \lambda w \right)$$

## 四、实验结果与分析

### 1. 生成数据


首先, 先产生若干符合高斯分布的样本点, 其中反例均值为  $[-1, -0.3]$ , 正例均值为  $[0.8, 0.3]$ , 方差均为  $0.2$ , 若不满足贝叶斯假设, 则协方差为:  $0.1$ 。训练集的样本点数为  $50$ , 测试集的样本点数为  $100$ , 学习速率为  $1$ , 正则项系数为  $0.01$ , 精度为  $10^{-5}$ 。

### 2. 四次实验如下

#### 2.1. 有惩罚项, 满足贝叶斯假设


对于有惩罚项, 满足贝叶斯假设的测试集和训练集, 我们的到了如下结果:

- 梯度下降法




其中训练集的准确率为：97%，测试集的准确率为 99%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 牛顿法



其中训练集的准确率为：97%，测试集的准确率为 98.5%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 共轭梯度法




其中训练集的准确率为：84%，测试集的准确率为 83%。可以看到 `logistics` 回归在使用共轭梯度法时，取得的效果并不是很理想。

## 2.2. 有惩罚项，不满足贝叶斯假设


对于有惩罚项，不满足贝叶斯假设的测试集和训练集，我们的到了如下结果：

- 梯度下降法



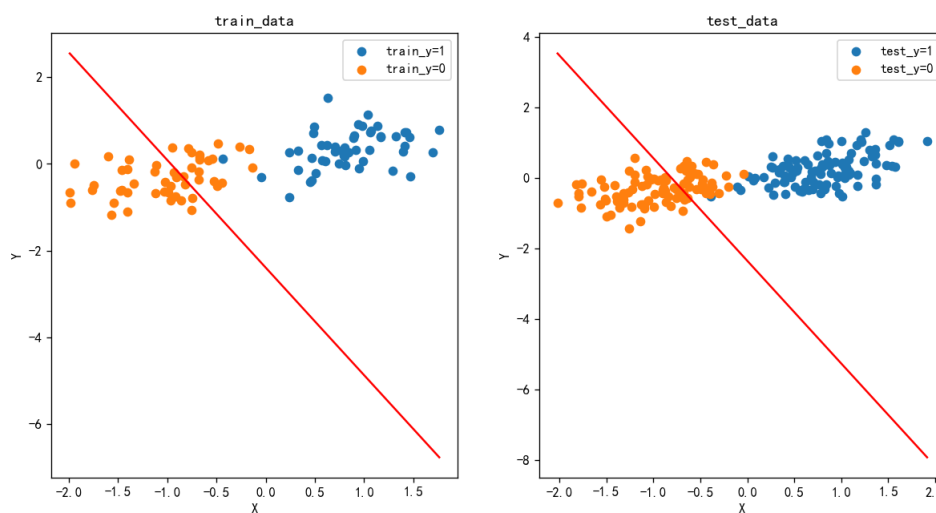
其中训练集的准确率为：96%，测试集的准确率为 98.5%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 牛顿法



其中训练集的准确率为：98%，测试集的准确率为 95.5%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 共轭梯度法




其中训练集的准确率为：81%，测试集的准确率为 83.5%。可以看到 `logistics` 回归在使用共轭梯度法时，取得的效果并不是很理想。



## 2.3. 无惩罚项，满足贝叶斯假设


对于无惩罚项，满足贝叶斯假设的测试集和训练集，我们的到了如下结果：

- 梯度下降法




其中训练集的准确率为：98%，测试集的准确率为 99%。可以看到 **logistics** 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 牛顿法



其中训练集的准确率为：99%，测试集的准确率为 98%。可以看到 logistics 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 共轭梯度法

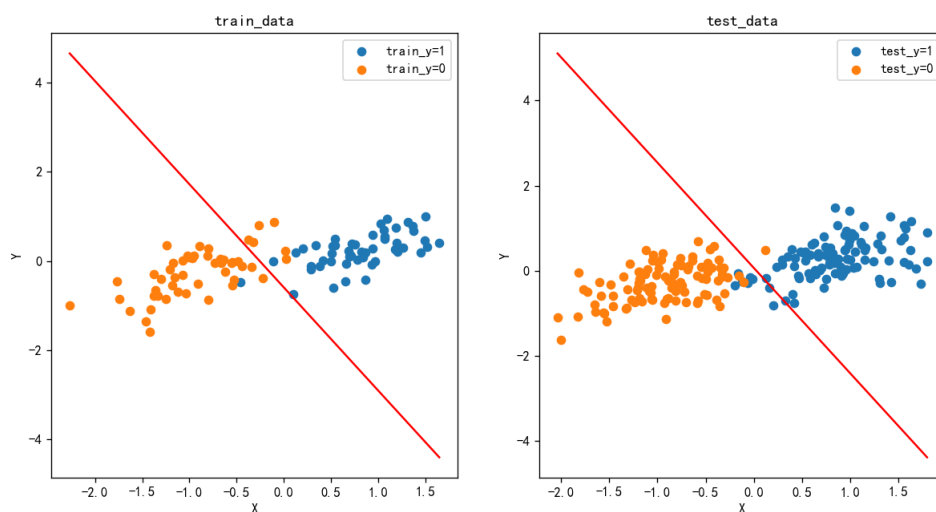


其中训练集的准确率为：81%，测试集的准确率为 85%。可以看到 logistics 回归在使用共轭梯度法时，取得的效果并不是很理想。

## 2.4. 无惩罚项，不满足贝叶斯假设


对于无惩罚项，不满足贝叶斯假设的测试集和训练集，我们的到了如下结果：

- 梯度下降法




其中训练集的准确率为：93%，测试集的准确率为 97.5%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

- 牛顿法



其中训练集的准确率为：90%，测试集的准确率为 91.5%。可以看到 `logistics` 回归在此时取到了较好的分类效果，可以明显地分开两个类。

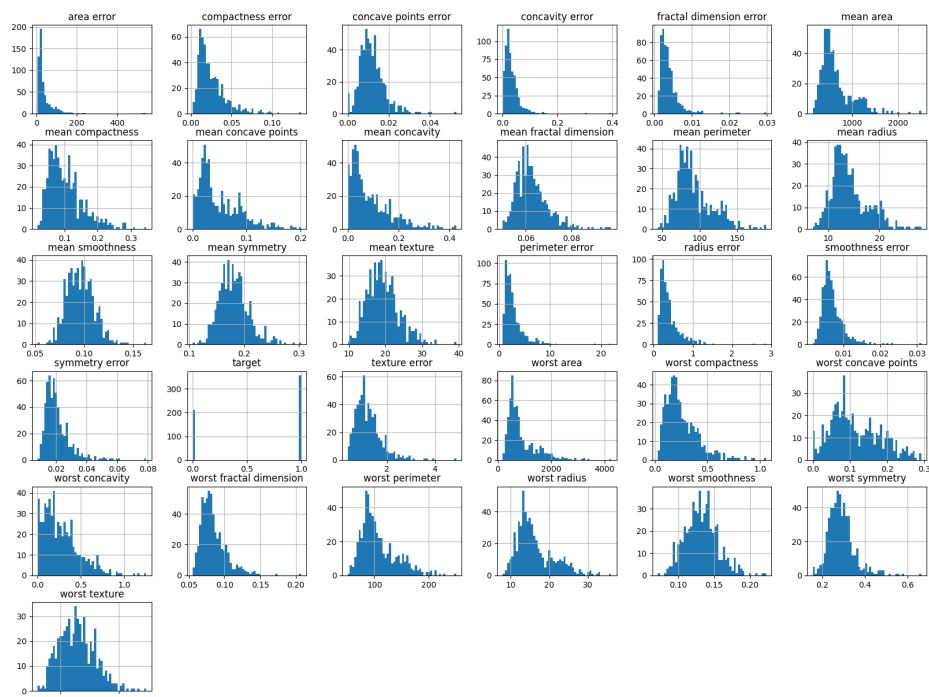
- 共轭梯度法



其中训练集的准确率为：85%，测试集的准确率为 84%。可以看到 logistics 回归在使用共轭梯度法时，取得的效果并不是很理想。

### 3.UCI 数据集

UCI 数据集中的 `breast_cancer` 数据集是简单经典的用于二分类任务的数据集。本次实验采用乳腺癌数据集进行 logistics 回归模型的测试。原数据集中有 30 个特征，样本数量为 569。各个样本的特征如下：



在本次实验中，首先将数据进行归一化处理，然后代入模型进行测试，结果测试集中的准确率为：63.6%，测试集的准确率为：61.4%。可以看到无论是测试集还是训练集，模型的准确率都很低。经分析，主要原因是，我写的这个 `logistics` 模型只适用于线性可分的数据集，而本数据集是线性不可分的，因此训练出的效果极差。

## 五、结论

- 对于梯度下降法，和牛顿法，`logistics` 回归的效果较好，但共轭梯度法的效果较差
- 对于牛顿法，由于需要计算二阶导数（或黑塞矩阵）的逆，其收敛速度较慢，而且还可能不存在逆。
- 从实验可以看出，当数据集满足朴素贝叶斯假设时 `logistics` 回归模型的分类表现略好于不满足朴素贝叶斯假设时的

## 六、参考文献

- (1) 周志华著. 机器学习, 北京: 清华大学出版社, 2016.1
- (2) 李航著. 统计学习方法, 北京: 清华大学出版社, 2020.6

## 七、附录：源代码（带注释）

源代码见相关文件

- (1) `gd.py`: 数据预处理, 生成, 梯度下降法, 牛顿法, 共轭梯度法的 `logistics` 模型
- (2) `test01.py-test04.py`: 梯度下降法在数据集是否满足贝叶斯假设, 是否含正则项的求解过程及绘图
- (3) `nt_test01.py-nt_test04.py`: 牛顿法在数据集是否满足贝叶斯假设, 是否含正则项的求解过程及绘图
- (4) `gc_test01.py-gc_test04.py`: 共轭梯度法在数据集是否满足贝叶斯假设, 是否含正则项的求解过程及绘图
- (5) `cancer.py` 乳腺癌数据集进行 `logistics` 回归模型的测试及绘图